論文紹介：A Critical Review of Recurrent Neural Networks for Sequence Learning

書誌情報

- タイトル：A Critical Review of Recurrent Neural Networks for Sequence Learning（系列学習のための再帰型ニューラルネットワークの批判的総説）
- 著者：Zachary C. Lipton, John Berkowitz, Charles Elkan（UC San Diego）
- 掲載：arXiv:1506.00019 [cs.LG]、プレプリント（査読なし）。v4、2015年。本文の日付は2015年6月5日
- 本文31ページ（p.32〜38 は参考文献）
- 種類：総説論文。著者ら自身の新しい実験はない。RNN の仕組み・学習法・応用を、表記を統一して解説している

用語

- 再帰型ニューラルネットワーク（recurrent neural network, RNN）：隣り合う時刻をつなぐ辺を持ち、前の時刻の状態を次の時刻に引き継ぐネットワーク。木構造に沿って計算する recursive neural network とは別物である
- 系列（sequence）：順序のあるデータ点の並び $(\boldsymbol{x}^{(1)}, \ldots, \boldsymbol{x}^{(T)})$。時刻は上付きの括弧で書く

Introduction

大きな目的・背景

- ニューラルネットワークは、教師あり学習・教師なし学習の幅広い課題で最先端の成果を出している。しかし標準的なネットワークは、データ同士が独立であることと、入力が固定長であることを前提にしている。
- 動画のフレーム、音声、文中の単語のように時間や順序で関係しあうデータでは、この前提が成り立たない。
- RNN は系列を1要素ずつ処理しながら、時刻をまたいで情報を受け渡せる。そのため、独立でない系列の入出力を扱える。
- 📍 p.1–2 §1 第1–2段落

解決すべき問題：なぜ RNN なのか

著者らは、読者が抱く3つの疑問に答える形で RNN を使う理由を示している。

疑問	著者らの答え	📍
系列性を明示的にモデル化する必要があるか	固定長のウィンドウでは長距離の依存関係を扱えない。長さ5のウィンドウでは「6時刻前のデータは何か」に答えられない	p.3 §1.1
マルコフモデルではだめか	HMM は状態数 $\lvert S\rvert$ に対して計算量 $O(\lvert S\rvert^2)$ で、ウィンドウを広げると状態数が指数的に増える。RNN は N 個の隠れノードで 2^N 以上の状態を表現でき、計算量はたかだか2乗でしか増えない	p.3–4 §1.2

疑問	著者らの答え	📍
RNN は表現力が高すぎないか	チューリング完全だが、構造を固定すれば微分可能で勾配法で学習でき、正則化で過学習も抑えられる	p.4–5 §1.3

意義と小さな目的

- RNN の文献は、表記が論文ごとにばらばらで、図も不十分なため初学者には読みにくい。例えば t が時刻と目標値の両方を表すことがある。
- 本稿の目的は、表記を統一した読みやすい総説として、最先端の RNN について歴史的な視点と一次文献への参照を備えた自己完結的な説明を提供することである。
- 📍 p.1 Abstract、p.5 §1.4

キーワード

RNN、BPTT（時間方向の誤差逆伝播法）、勾配消失・勾配爆発、LSTM、双方向 RNN（BRNN）、ニューラルチューリングマシン、sequence to sequence

本論の要点

2章 背景：順伝播型ネットワークと誤差逆伝播法

- ノード j の値は、入力の重み付き和 a_j に活性化関数 l_j を適用して求める。重み $w_{jj'}$ は j' から j への辺を表す（「to-from」の順）。

$$v_j = l_j\left(\sum_{j'} w_{jj'} \cdot v_{j'}\right)$$

- 学習は、損失 $\mathcal{L}$ の勾配を誤差逆伝播法で求め、SGD（確率的勾配降下法）で重みを更新する。損失曲面は非凸なので、大域的最小値に到達する保証はない。
- 📍 p.6–10 §2.2–2.3

3章 RNN の定義と学習の困難

- **定義**：RNN は、隣り合う時刻をつなぐ辺（再帰辺）を順伝播型ネットワークに加えたものである。単純な RNN の順伝播は次の2式で書ける（図3）。

$$\boldsymbol{h}^{(t)} = \sigma\left(W^{\mathrm{hx}}\boldsymbol{x}^{(t)} + W^{\mathrm{hh}}\boldsymbol{h}^{(t-1)} + \boldsymbol{b}_h\right)$$

$$\hat{\boldsymbol{y}}^{(t)} = \mathrm{softmax}\left(W^{\mathrm{yh}}\boldsymbol{h}^{(t)} + \boldsymbol{b}_y\right)$$

- ここで、W^{hx} は入力→隠れ層、W^{hh} は隠れ層→次時刻の隠れ層（再帰）、W^{yh} は隠れ層→出力の重み行列である。
- **BPTT**：時間方向に展開すると（図4）、RNN は全時刻で重みを共有する深いネットワークとみなせる。これに誤差逆伝播法を適用するのが BPTT（Werbos, 1990）である。
- **初期の RNN**：Hopfield（1982）、Jordan（1986, 出力を次時刻に戻す）、Elman（1990, 隠れ層を重み1の辺で次時刻に戻す）。Elman の「重みを固定した自己結合」は LSTM の基礎になった。
- **勾配消失・爆発**：再帰辺の重みは全時刻で同じなので、時刻 τ の入力が時刻 t の出力に与える寄与は、$t-\tau$ に対して指数的に爆発するか消失する（図7・図8）。$|w| < 1$ かシグモイドなら消失、ReLU

なら爆発が起こりやすい。
- **対策**：打ち切り BPTT は勾配爆発を抑えるが、長距離の依存関係を学習できなくなる。勾配消失には LSTM が有効である。局所最適解については、大きなネットワークでは臨界点の大半が鞍点であり、従来考えられていたほど深刻ではない可能性がある（Dauphin et al., 2014）。
- 📍 p.10–16 §3、図3・4・7・8

4章 現代のアーキテクチャ

LSTM（Hochreiter and Schmidhuber, 1997）

- 隠れ層のノードを記憶セルに置き換える（図9・図10）。記憶セルの中心にある内部状態 s は重み1で固定した自己結合（定誤差カルーセル）を持つ。そのため、勾配は消失も爆発もせずに多くの時刻を通過できる。
- 入力ゲート i、忘却ゲート f、出力ゲート o が、情報をいつ入れ、いつ消し、いつ出すかを学習する。忘却ゲート付き LSTM の計算は次のとおりである（ϕ は tanh、$\odot$ は要素ごとの積）。

$$
\begin{aligned}
\boldsymbol{g}^{(t)} &= \phi\left(W^{\mathrm{gx}}\boldsymbol{x}^{(t)} + W^{\mathrm{gh}}\boldsymbol{h}^{(t-1)} + \boldsymbol{b}_g\right) \\
\boldsymbol{i}^{(t)} &= \sigma\left(W^{\mathrm{ix}}\boldsymbol{x}^{(t)} + W^{\mathrm{ih}}\boldsymbol{h}^{(t-1)} + \boldsymbol{b}_i\right) \\
\boldsymbol{f}^{(t)} &= \sigma\left(W^{\mathrm{fx}}\boldsymbol{x}^{(t)} + W^{\mathrm{fh}}\boldsymbol{h}^{(t-1)} + \boldsymbol{b}_f\right) \\
\boldsymbol{o}^{(t)} &= \sigma\left(W^{\mathrm{ox}}\boldsymbol{x}^{(t)} + W^{\mathrm{oh}}\boldsymbol{h}^{(t-1)} + \boldsymbol{b}_o\right) \\
\boldsymbol{s}^{(t)} &= \boldsymbol{g}^{(t)} \odot \boldsymbol{i}^{(t)} + \boldsymbol{s}^{(t-1)} \odot \boldsymbol{f}^{(t)} \\
\boldsymbol{h}^{(t)} &= \phi\left(\boldsymbol{s}^{(t)}\right) \odot \boldsymbol{o}^{(t)}
\end{aligned}
$$

- 本稿で取り上げる最先端の応用研究の多くは LSTM を使っている。
- 📍 p.17–21 §4.1、図9–11

BRNN（Schuster and Paliwal, 1997）

- 順方向 $\boldsymbol{h}^{(t)}$ と逆方向 $\boldsymbol{z}^{(t)}$ の2つの隠れ層を持ち、出力を過去と未来の両方から決める（図12）。品詞タグ付けのように、系列全体が手元にある課題に向く。
- 未来の入力が必要なので、オンラインの用途には使えない。
- LSTM と組み合わせた BLSTM は、手書き文字認識と音素分類で最先端の結果を出した。
- 📍 p.21–22 §4.2、図12

ニューラルチューリングマシン（NTM, Graves et al., 2014）

- RNN に、読み書きヘッドを介してアクセスする外部メモリ行列を加えたもの。端から端まで微分可能である。
- コピーや優先度ソートの課題で、LSTM より高い性能を示し、訓練データより長い入力にも汎化した。
- 📍 p.22–23 §4.3

5章 応用と評価

- **入出力の形**：RNN は「系列→1出力」「1入力→系列」「系列→系列」をすべて扱える（図13）。
- **単語の表現**：one-hot 符号化は非効率で、単語間の類似性を表せない。そのため word2vec や GloVe の分散表現を使うのが一般的である。

- **評価指標**：翻訳やキャプションの評価には BLEU（n グラム適合率の幾何平均×短さペナルティ）や METEOR が使われる。ただし1文単位では人間の判断と一致しない。
- **主な結果**

課題	手法	結果	📍
英→仏翻訳	2つの多層 LSTM による sequence to sequence（Sutskever et al., 2014）	BLEU 34.81。リランキングでは 36.5。GPU 8台で10日	p.27–29 §5.3、図14
画像キャプション生成	CNN で符号化し、LSTM・RNN で復号（Vinyals et al., 2015 など）	Mao et al.（2014）が Pascal・Flickr30K・COCO で当時の最先端	p.29–30 §5.4
手書き文字認識	双方向 LSTM（Graves et al., 2009）	単語正解率 81.5%（HMM は 70.1%）	p.30 §5.5
プログラム実行の予測	多層 LSTM（Zaremba and Sutskever, 2014）	9桁の足し算などで正解率 99%	p.30 §5.5

- 📍 p.23–30 §5、図13

考察（6章）

事実として述べていること

- RNN は30年で、認知モデリングの対象から大規模な教師あり学習の実用的な道具になった。進歩の要因は、アーキテクチャ、学習アルゴリズム、並列計算である。
- LSTM と BRNN の成功は、根本的に新しいアルゴリズムではなく、新しいアーキテクチャから生まれている。
- 📍 p.30–31 §6 第1–2段落

著者らの意見・提言

- 研究者コミュニティは、遺伝的アルゴリズムのように技術を組み合わせ、主要データセットの評価指標を適応度として、モデルの空間を探索している。そのため、モデル探索を自動化すると有益である。
- BLEU のような評価指標は信頼性が低い。新しい技術は、まず評価の確立した順伝播型ネットワークの課題で試すべきである。
- 長い文章や対話システム（会話の履歴全体を文脈として保持する）への拡張が有望である。
- 📍 p.31 §6 第2–4段落

Conclusion

本稿は、系列データを扱う RNN について、定義、BPTT による学習、勾配消失・爆発という困難、それを解決した LSTM と BRNN、外部メモリを持つ NTM、そして翻訳・キャプション生成・手書き文字認識での成果を、統一した表記で解説した総説である。著者らは、近年の進歩は主にアーキテクチャの工夫によるものだと結論し、モデル探索の自動化とよりよい評価指標が今後必要だと述べている。

元論文を読むときの注意点

位置	内容
p.20 LSTM の式	$\boldsymbol{s}^{(t)}$ の式の $\boldsymbol{i}^{(i)}$ は $\boldsymbol{i}^{(t)}$ の誤植である
p.8 と p.13–14	同じ最適化問題を「NP 困難」とも「NP 完全」とも書いている
p.12–13	Elman の実験を「2種類」と書きながら、紹介しているのは XOR の1つだけである
p.26	BLEU と METEOR で、記号 c が別の量を表している

詳しい段落ごとの要旨は survey_critical_review_rnn.md にある。