論文紹介：A Critical Review of Recurrent Neural Networks for Sequence Learning

書誌情報

- タイトル：A Critical Review of Recurrent Neural Networks for Sequence Learning（系列学習のための再帰型ニューラルネットワークの批判的総説）
- 著者：Zachary C. Lipton, John Berkowitz, Charles Elkan（UC San Diego）
- 掲載：arXiv 2015年6月5日
- URL:https://arxiv.org/abs/1506.00019
- 種類：総説論文

Abstract

- 系列データ（sequential data）を扱う学習タスクは無数にある
    - モデルが系列を出力する必要があるタスク
        - 画像キャプションの生成
        - 音声合成
        - 音楽生成
    - モデルが系列の入力から学習する必要があるタスク
        - 時系列予測
        - 動画解析
        - 音楽情報検索
    - 対話型（interactive）のタスクは、多くの場合この両方を必要とする
        - 自然言語の翻訳
        - 対話
        - ロボットの制御
- これらの学習には再帰型ニューラルネットワーク（RNN）をを使うことで系列のダイナミクスを捉えた学習を行うことができる。
- 近年は、長短期記憶（long short-term memory; LSTM）や双方向 RNN（bidirectional RNN; BRNN）に基づくシステムが、次のようなタスクで画期的な性能を示している。
    - 画像キャプションの生成
    - 言語翻訳
    - 手書き文字認識
- 本稿では、この強力な学習モデルを過去30年で生み出し、実用化した研究を概観し、統合する。
- 必要に応じて、互いに食い違う表記法や用語を整理する。

1. 導入

- ニューラルネットワークは、教師あり学習・教師なし学習の幅広い課題で最先端の成果を出している。しかし標準的なネットワークは、データ同士が独立であること、入力が固定長であることを前提にしている。

- 動画のフレーム、音声、文中の単語のように時間や順序で関係しあうデータを扱う場合は、この前提が成り立たない。

- RNN は系列を1要素ずつ処理しながら、時刻をまたいで情報を受け渡せる。そのため、独立でない系列の入出力を扱うことができる。
- 表記が論文ごとに異なったり，同じ記号を複数の意味で使ったりすることで初学者の混乱を招いている
    - 添字がノードと時刻の両方を表す
    - h が活性化関数と隠れ層の両方を表す
    - t が時刻と目標値の両方を表す。

2. 背景

- 以下のような表記を用いて、系列、ニューラルネットワーク、順伝播型ニューラルネットワークに関する誤差逆伝播法と勾配降下法について説明している。
    - 時刻tにおける入力： $\boldsymbol{x}^{(t)}$ 時刻は上付きの括弧で書く
    - 時刻tにおける目標値：$\boldsymbol{y}^{(t)}$
    - 時刻tにおける予測値：$\hat{\boldsymbol{y}}^{(t)}$
    - 時刻tにおける隠れ層の値：$\boldsymbol{h}^{(t)}$
    - ノードの番号：j, j'
    - ノードjの活性化関数：$l_j(\cdot)$
    - ノードj'からjへの重み：$w_{jj'}$
- 学習は、損失 $\mathcal{L}$ の勾配を誤差逆伝播法で求め、SGD（確率的勾配降下法）で重みを更新する。損失曲面は非凸（谷が複数ある形）なので、到達したのが局所解ではないとする保証はない。

3. リカレントニューラルネットワーク

- **定義**：RNN は、隣り合う時刻をつなぐ辺（再帰辺）を順伝播型ネットワークに加えたものである。単純な RNN の順伝播は次の2式で書ける（図3）。

$$\boldsymbol{h}^{(t)} = \sigma\left(W^{\mathrm{hx}}\boldsymbol{x}^{(t)} + W^{\mathrm{hh}}\boldsymbol{h}^{(t-1)} + \boldsymbol{b}_h\right)$$

$$\hat{\boldsymbol{y}}^{(t)} = \mathrm{softmax}\left(W^{\mathrm{yh}}\boldsymbol{h}^{(t)} + \boldsymbol{b}_y\right)$$

- ここで、W^{hx} は入力→隠れ層、W^{hh} は隠れ層→次時刻の隠れ層（再帰）、W^{yh} は隠れ層→出力の重み行列である。
- BPTT：図4のように時間方向に展開すると（図4）、RNN は全時刻で重みを共有する深いネットワークとみなせる。これに誤差逆伝播法を適用するのが BPTT（Werbos, 1990）である。

3.1 初期の再帰型ネットワーク

Hopfield ネットワーク（Hopfield, 1982）

- 目的：パターン認識（連想記憶）
- 構造：ノード間の重みで定義される。活性化関数は0を閾値とする閾値関数
- 使い方：パターンを入れて、更新規則に従って動かし、落ち着いたパターンを読み出す
- できること：壊れたパターンから、記憶したパターンを復元する
- 後への影響：ボルツマンマシン、オートエンコーダの先駆け
- 注意：系列学習のモデルではない

Jordan ネットワーク（Jordan, 1986）

- 目的：系列の教師あり学習
- 構造（図5）
  - 隠れ層1層の順伝播型ネットワーク
  - 出力を文脈ユニットにコピーし、次の時刻の隠れ層に送る
  - 文脈ユニットは自己結合を持つ
- できること：過去の出力（例：とった行動）を覚えておける
- 後への影響：生成した単語を次の入力にする翻訳モデル（Sutskever et al., 2014）

Elman ネットワーク（Elman, 1990）

- 目的：時間的な依存関係を学習する
- 構造（図6）
  - 隠れ層の1時刻前の値を、重み1で固定した辺で文脈ユニットにコピーする
  - 文脈ユニットの値を、通常の辺で隠れ層に戻す
- 後への影響：重みを固定した自己結合の考えが LSTM の基礎になった

3.2 再帰型ネットワークの学習

勾配消失・勾配爆発

- 原因：多くの時刻にわたって誤差を逆伝播するため
  - 例（図7）：入力1・隠れ1・出力1のネットワーク。時刻 τ の入力が時刻 t の出力に与える寄与を考える
  - 再帰辺の重みは全時刻で同じなので、寄与は $t-\tau$ に対して指数的に爆発するか0に近づく
- 起こりかた
  - $|w_{jj}|>1$ なら爆発、$|w_{jj}|<1$ なら消失（図8）
  - シグモイドでは消失、ReLU では爆発が起こりやすい
- 理論：Pascanu et al.（2012）が起こる条件を示し、勾配が消失も爆発もしない値に重みを保つ正則化項を提案した

対策

- 打ち切り BPTT（TBPTT）（Williams and Zipser, 1989）
  - 逆伝播する時刻数に上限を設ける
  - 勾配爆発を抑えられるが、上限より前の依存関係は学習できなくなる
- LSTM：重み1で固定した再帰辺を持つノードで勾配消失を解決する（§4.1）

局所最適解

- 隠れ層1層の順伝播型でも最適化は NP困難である（Blum and Rivest, 1993）
- しかし大きなネットワークでは、臨界点の大半は局所最小値ではなく**鞍点**で、その比率はネットワークの大きさに対して指数的に増える（Dauphin et al., 2014）。かつて考えられていたほど深刻ではない可能性がある

4 現代の RNN アーキテクチャ

4.1 LSTM（Long Short-Term Memory）

- 目的：勾配消失を克服する
- 構成要素（図9・図10）

要素	記号	活性化関数
入力ノード	g	tanh（元の論文はシグモイド）
入力ゲート	i	シグモイド
内部状態	s	線形
忘却ゲート	f	シグモイド
出力ゲート	o	シグモイド

- 式（忘却ゲート付き。⊙ は要素ごとの積）

$$
\begin{aligned}
\boldsymbol{g}^{(t)} &= \phi\left(W^{\mathrm{gx}}\boldsymbol{x}^{(t)} + W^{\mathrm{gh}}\boldsymbol{h}^{(t-1)} + \boldsymbol{b}_g\right) \\
\boldsymbol{i}^{(t)} &= \sigma\left(W^{\mathrm{ix}}\boldsymbol{x}^{(t)} + W^{\mathrm{ih}}\boldsymbol{h}^{(t-1)} + \boldsymbol{b}_i\right) \\
\boldsymbol{f}^{(t)} &= \sigma\left(W^{\mathrm{fx}}\boldsymbol{x}^{(t)} + W^{\mathrm{fh}}\boldsymbol{h}^{(t-1)} + \boldsymbol{b}_f\right) \\
\boldsymbol{o}^{(t)} &= \sigma\left(W^{\mathrm{ox}}\boldsymbol{x}^{(t)} + W^{\mathrm{oh}}\boldsymbol{h}^{(t-1)} + \boldsymbol{b}_o\right) \\
\boldsymbol{s}^{(t)} &= \boldsymbol{g}^{(t)} \odot \boldsymbol{i}^{(t)} + \boldsymbol{s}^{(t-1)} \odot \boldsymbol{f}^{(t)} \\
\boldsymbol{h}^{(t)} &= \phi\left(\boldsymbol{s}^{(t)}\right) \odot \boldsymbol{o}^{(t)}
\end{aligned}
$$

- 順伝播：入力ゲートが0なら何も入らない。両方のゲートが閉じていれば、値は記憶セルに閉じ込められる
- 逆伝播：定誤差カルーセルによって、勾配は消失も爆発もせずに多くの時刻をさかのぼれる
- のぞき穴結合（Gers and Schmidhuber, 2000）
  - 内部状態からゲートへ直接つなぐ結合
  - 例：物体を n 個数えたら出力する課題では、出力ゲートが内部状態の値を知る必要がある
- 図11のように各セルの出力は、次の時刻にすべてのセルの入力ノードとゲートに入る。層を重ねることも多い

4.2 双方向 RNN（BRNN）

- 図12のように順方向の隠れ層 $\boldsymbol{h}$ と逆方向の隠れ層 $\boldsymbol{z}$ の2つを持ち、どちらも入力と出力につながる
- 式

$$
\begin{aligned}
\boldsymbol{h}^{(t)} &= \sigma\left(W^{\mathrm{hx}}\boldsymbol{x}^{(t)} + W^{\mathrm{hh}}\boldsymbol{h}^{(t-1)} + \boldsymbol{b}_h\right) \\
\boldsymbol{z}^{(t)} &= \sigma\left(W^{\mathrm{zx}}\boldsymbol{x}^{(t)} + W^{\mathrm{zz}}\boldsymbol{z}^{(t+1)} + \boldsymbol{b}_z\right) \\
\hat{\boldsymbol{y}}^{(t)} &= \mathrm{softmax}\left(W^{\mathrm{yh}}\boldsymbol{h}^{(t)} + W^{\mathrm{yz}}\boldsymbol{z}^{(t)} + \boldsymbol{b}_y\right)
\end{aligned}
$$

- 向いている課題：長さが決まった系列の予測（例：品詞タグ付け。前後の単語の両方が手がかりになる）
- 限界：未来と過去の両方に終点が必要なので、動き続けられない。オンラインの用途には使えない

- **LSTM との組み合わせ（BLSTM）**：LSTM は隠れ層の部品、BRNN は隠れ層の配線なので両立する。手書き文字認識・音素分類で最先端

4.3 ニューラルチューリングマシン（NTM）

- 目的：ソートのような複雑なアルゴリズム的課題を解く
- 人間の「中央実行系」とメモリバッファ（認知科学）、チューリング機械のテープとヘッドから発想を得た
- 構成
  - コントローラ：RNN か順伝播型ネットワーク
  - メモリ行列：N 個の記憶場所 × M 次元
  - 読み取り・書き込みヘッド
- 学習：BPTT を使い、確率的勾配降下法で学習できる
- 実験（Graves et al., 2014）
  - コピー課題、優先度ソート課題など5つ
  - NTM は訓練データより長い入力にも汎化した。外部メモリのない LSTM は汎化しなかった
  - どの課題でも、2種類の NTM が LSTM を大きく上回った

5. LSTMとBRNNの応用

- RNNによる出入力の形と応用例（図13）
  - (a) 1入力 → 1出力：標準的な順伝播型（独立な場合）
  - (b) 系列 → 1出力：文章・動画の分類
  - (c) 1入力 → 系列：画像キャプション生成
  - (d) 系列 → 系列（長さが異なってよい）：翻訳
  - (e) 系列 → 系列（各時刻に出力）：次の文字を予測する文章生成
- 自然言語の評価指標①BLEU
  - 参照が複数ある自然言語出力でよく使う指標が BLEU（Papineni et al., 2002）である。
  - 修正ユニグラム適合率に関係する指標で、$n = 1$ から上限 N までの n グラム適合率の幾何平均をとる。
  - 実際には $N = 4$ がよく使われ、人間の評価者との一致が最大になることが示されている。
  - 訳を極端に短くすれば適合率を高くできるので、BLEU には短さへのペナルティ B を入れる。c を候補訳の平均の長さ、r を参照訳の平均の長さとすると、BLEUスコアは以下のように計算される

$$B = \begin{cases} 1 & (c > r) \\ e^{(1-r/c)} & (c \leq r) \end{cases}$$

$$\mathrm{BLEU} = B \cdot \exp\left(\frac{1}{N} \sum_{n=1}^{N} \log p_n \right)$$

- 自然言語の評価指標②METEOR
  - METEOR（Banerjee and Lavie, 2005）は BLEU の弱点を克服するための指標である。
    - 候補文と参照文の単語どうしの明示的な一致に基づく。参照が複数あれば最もよいスコアを使う。
    - BLEU と違い、既知の同義語と語幹の一致も使う。

- 計算手順
  - まず、単語の一致に基づいて F 値を計算する。ここで、P は適合率、R は再現率である。
  - 次に、断片化ペナルティ $M \propto c/m$ を計算する。
    - c：候補と参照の両方で単語が隣り合っている、連続した単語のかたまり（chunk）の最小数
    - m：一致したユニグラムの総数

$$F_\alpha = \frac{P \cdot R}{\alpha \cdot P + (1-\alpha) \cdot R}$$

$$\mathrm{METEOR} = (1 - M) \cdot F_\alpha$$

6.考察

- RNN は30年で、認知モデリングの対象から大規模な教師あり学習の実用的な道具になった。進歩の要因は、アーキテクチャ、学習アルゴリズム、並列計算である。
- LSTM と BRNN の成功は、根本的に新しいアルゴリズムではなく、新しいアーキテクチャから生まれている。
- 研究者コミュニティは、遺伝的アルゴリズムのように技術を組み合わせ、主要データセットの評価指標を適応度として、モデルの空間を探索している。そのため、モデル探索を自動化すると有益である。
- BLEU のような評価指標は信頼性が低い。新しい技術は、まず評価の確立した順伝播型ネットワークの課題で試すべきである。
- 長い文章や対話システム（会話の履歴全体を文脈として保持する）への拡張が有望である。