

神経細胞シミュレーションの 計算コスト削減を目的とした RNN代理モデルの構築


山口大学 理学部 物理・情報科学科
生体情報システム研究室
山下 陽平

神経細胞と脳機能

脳：生物の思考や行動といった情報処理を司る器官

$10^9 \sim 10^{11}$ 個の神経細胞によってネットワークを構成

細胞間は神経伝達物質と電気刺激によって情報を伝達



神経細胞の数理モデル


電流刺激に対する膜電位応答

→ 連立の非線形な
常微分方程式を解くと求まる

内部に複数の状態変数を持つ

各状態変数を数値積分

→ 時間計算量
空間計算量 ともに大きい



Hodgkin-Huxleyモデル(1952)

例：Hodgkin-Huxleyモデル

$$C \frac{dV}{dt} = -g_{\text{leak}}(V - E_{\text{leak}}) - \bar{g}_{\text{Na}} m^3 h (V - E_{\text{Na}}) - \bar{g}_{\text{K}} n^4 (V - E_{\text{K}}) + I_{\text{ext}}(t)$$

$$\frac{dm}{dt} = \alpha_m(V)(1 - m) - \beta_m(V)m \quad \frac{dh}{dt} = \alpha_h(V)(1 - h) - \beta_h(V)h \quad \frac{dn}{dt} = \alpha_n(V)(1 - n) - \beta_n(V)n$$

$$\alpha_m = \frac{0.1(V + 40)}{1 - e^{-(V + 40)/10}}$$

$$\beta_m = 4e^{-(V + 65)/18}$$

$$\alpha_h = 0.07e^{-(V + 65)/20}$$

$$\beta_h = \frac{1}{1 + e^{-(V + 35)/10}}$$

$$\alpha_n = \frac{0.01(V + 55)}{1 - e^{-(V + 55)/10}}$$

$$\beta_n = 0.125e^{-(V + 65)/80}$$


$$C = 1.0, \quad \bar{g}_{\text{Na}} = 120, \quad \bar{g}_{\text{K}} = 36, \quad g_{\text{leak}} = 0.3, \quad E_{\text{Na}} = 50, \quad E_{\text{K}} = -77, \quad E_{\text{leak}} = -54.387$$

大規模シミュレーション

全脳をシミュレーションする場合
神経細胞モデルを $10^9 \sim 10^{11}$ 個




計算コストが大きすぎるので
神経細胞1つあたりの計算量を
減らさなければならない




Kuniyoshi et al.2023

RNN代理モデル

従来のモデル



RNNによる代理モデル



なぜRNN？

どちらも内部状態を保持

膜電位は入力履歴に依存する

例：不応期，閾値下での電位の蓄積

→ 微分eq による積分も RNN も
内部状態を保持，1 ステップずつ
更新する

微分eq $s(t + \Delta t) = F(s(t), I(t))$

RNN $h(t) = G(h(t-1), x(t))$

GPU による高速化

微分eq

指数関数を含む微分方程式を
細胞ごとに逐次計算

RNN

全細胞で重みを共有し，
行列積でまとめて計算

細胞数の多いシミュレーションにおいても
GPUを使って高速に計算できるのではない
か

基になる数理モデル

Hodgkin-Huxleyモデル

空間形状を考慮しない
コンパートメント：1個

状態変数：ゲート変数
 その他変数

進行中

Multi-Compartmentモデル

空間形状を考慮
コンパートメント：複数個

状態変数：ゲート変数
 その他変数

より再現度の高い
シミュレーション

未着手

これまでやったこと

- ・ 先行研究調査
 - ・ HHモデルなどの論文から既存の微分方程式モデルの勉強
 - ・ イオンチャネル等の初歩的な生理学の勉強
- ・ RNNの勉強と簡単な実装と学習（sinカーブ）
- ・ 環境構築（学内GPUサーバに仮想環境UVを導入）
- ・ HHモデルにパルス電流を入力し、入出力の組を作る（教師データを作る）（途中）

今後の予定

スケジュール

～10月下旬

HH の教師データを生成
RNNを使って学習・評価 GPU並列化
→各ゲート変数に対しても学習を行うことも視野に

～11月15日

MC モデル (Traub) 実装

～年末

MCモデル (Traub) の教師データを生成
RNNを使って学習・評価

～2027年2月

卒論執筆