

神経細胞シミュレーションの 計算コスト削減を目的とした RNN代理モデルの構築


山口大学 理学部 物理・情報科学科
生体情報システム研究室
山下 陽平

神経細胞と脳機能

脳：生物の思考や行動といった情報処理を司る器官

$10^9 \sim 10^{11}$ 個の神経細胞によってネットワークを構成

細胞間は神経伝達物質と電気刺激によって情報を伝達



神経細胞の数値モデル


電流刺激に対する膜電位応答

→ 連立の非線形な
常微分方程式を解くと求まる

内部に複数の状態変数を持つ

各状態変数を数値積分

→ 時間計算量
空間計算量 ともに大きい





Hodgkin-Huxleyモデル(1952)

大規模シミュレーション

全脳をシミュレーションする場合
神経細胞モデルを $10^9 \sim 10^{11}$ 個




計算コストが大きすぎるので
神経細胞1つあたりの計算量を
減らさなければならない




RNN代理モデル

従来のモデル



RNNによる代理モデル



なぜRNN？

1 状態を持つ構造が同じ

膜電位は入力履歴に依存する

例：不応期，閾値下での電位の蓄積

→ HH も RNN も履歴を「状態」として持ち，
1ステップずつ更新する

$$\text{HH} \quad s(t + \Delta t) = F(s(t), I(t))$$

$$\text{RNN} \quad \mathbf{h}(t) = G(\mathbf{h}(t-1), \mathbf{x}(t))$$

2 GPU で高速化

HH

指数関数を含む微分方程式を
細胞ごとに逐次計算

RNN

全細胞で重みを共有し，
行列積でまとめて計算

細胞数が増えるほど高速化が期待できる

研究の問い：RNN の隠れ状態で HH モデルのダイナミクスを再現できるか

基になる数理モデル

Hodgkin-Huxleyモデル

空間形状を考慮しない
コンパートメント：1個

状態変数：ゲート変数
 その他変数

進行中

Multi-Compartmentモデル

空間形状を考慮
コンパートメント：10～20個

状態変数：ゲート変数
 その他変数

より再現度の高い
シミュレーション

調査中

Hodgkin-Huxleyモデル

$$C \frac{dV}{dt} = -g_{\text{leak}}(V - E_{\text{leak}}) - \bar{g}_{\text{Na}} m^3 h (V - E_{\text{Na}}) - \bar{g}_{\text{K}} n^4 (V - E_{\text{K}}) + I_{\text{ext}}(t)$$

$$\frac{dm}{dt} = \alpha_m(V)(1 - m) - \beta_m(V)m \quad \frac{dh}{dt} = \alpha_h(V)(1 - h) - \beta_h(V)h \quad \frac{dn}{dt} = \alpha_n(V)(1 - n) - \beta_n(V)n$$

$$\alpha_m = \frac{0.1(V + 40)}{1 - e^{-(V + 40)/10}}$$

$$\beta_m = 4e^{-(V + 65)/18}$$

$$\alpha_h = 0.07e^{-(V + 65)/20}$$

$$\beta_h = \frac{1}{1 + e^{-(V + 35)/10}}$$

$$\alpha_n = \frac{0.01(V + 55)}{1 - e^{-(V + 55)/10}}$$

$$\beta_n = 0.125e^{-(V + 65)/80}$$

$$C = 1.0, \quad \bar{g}_{\text{Na}} = 120, \quad \bar{g}_{\text{K}} = 36, \quad g_{\text{leak}} = 0.3, \quad E_{\text{Na}} = 50, \quad E_{\text{K}} = -77, \quad E_{\text{leak}} = -54.387$$


研究の進捗



今回の報告

- 1 ライブラリを使わず NumPy だけで RNN を実装し、勾配計算の正しさを検算
- 2 sin 波の予測で教科書の実装（PyTorch / Keras）と同等の精度を確認
- 3 HH モデルの教師データを生成し、HH × RNN の学習設計を決定

学習条件の検討（10 シード）



初期化 / Adam の実装 / 停止条件 を変えて各 10 回学習し，生成誤差を比較（対数軸，横線は中央値）

入力重み W の初期値が主因

標準偏差 1 $\rightarrow$ Xavier（約 0.2）で中央値が約 $1/20$ に

1 点先の誤差 $\neq$ 生成の良さ

val_loss 最良の条件と gen_mse 最良の条件が一致しない


EarlyStopping で稀に崩れる

停止の基準（1 点先）と評価（逐次生成）がずれる

HH の学習では Xavier 初期化 + Adam（AMSGrad）を採用し，評価は逐次生成で行う

HH モデルの教師データ

teacher_thesis (first 500 ms of 900 ms)



外部電流

振幅をランダムに変えるパルス電流

0~20 $\mu A/cm^2$, 10 ms ごとに更新

シミュレーション

$T = 900$ ms, $dt = 0.05$ ms

(18,000 ステップ)

ねらい

発火する・しない入力を両方含め、特定の入力に依存しない学習を目指す

条件は先行研究 [棟近 2025] に合わせた

HH × RNN の学習設計（実装中）



全時刻で 1 点ずつ対応させ、隠れ状態 h を途切れさせずに系列全体を学習

データ分割

時間順に分割（60 / 20 / 20）

訓練 0–540 ms

検証 540–720 ms

テスト 720–900 ms

前処理

I と V をそれぞれ標準化

平均・分散は訓練区間のみで計算

テスト区間の情報は使わない

評価指標

波形：RMSE / MAE

スパイク数・スパイク形状

計算時間・計算量

今後の予定と課題

スケジュール

～10月下旬

HH の教師データを生成
RNNを使って学習・評価
→各ゲート変数に対しても学習を行うことも視野に

～11月15日

MC モデル (Traub) 実装

～年末

MCモデル (Traub) の教師データを生成
RNNを使って学習・評価

～2027年2月

卒論執筆